classification

May 18, 2021

1 Classification

```
[1]: from pretraitement import TextPreTraitement
from clean import clean_claimKG
from classification import trueVSfalse, trueFalseVSmixture,

→trueVSfalseVSmixture, cut_data
from utilities import plot_confusion_matrix
```


```
[3]: file_name = "../data/claimKG.csv"
origin = pd.read_csv(file_name)
origin = clean_claimKG(origin, verbose=False, inplace=True)
```

1.1 Découpage des données

Ici nous générons trois groupes de données

- kg tf contient les deux classes True -> 1 et False -> 0.
- kg_tf_m contient les deux classes True-False -> 0 et Mixture -> 1.
- kg_tfm contient les trois classes True -> 1, False -> 0 et Mixture -> 2

[6]: <AxesSubplot:title={'center':'Distibution des données True VS False'}>




Comme afficher dans la cellule précedente, le nombre d'assertions pour chaque classe est mal balancé. Ce qui peut conduire à un mauvais apprentissage de la part des modèles. En effet, par exemple, dans la tâche **True** VS **False**, il y a 70% d'assertions **False**. le modèle va donc être biaisé et être moins performant pour la prédiction des assertions **False**.

On a donc mis en point une fonction de sous-échantillonnage (Downsampling) pour remédier à ce problème.

```
[11]: kg = kg_tf_m[:15000]
index = index_tf_m

downsampling = True
if downsampling:
    kg = cut_data(kg)
    print(kg['ratingValue'].value_counts().rename(index=index).plot(
        kind='bar',title="Distribution apres downsampling"))
```

AxesSubplot(0.125,0.125;0.775x0.755)



1.2 Classification

1.2.1 Jeu d'apprentissage et de test

Dans cette étape nous procédant à la création d'un jeu d'apprentissage et de test en utilsant la fonction train_test_split de la librairie sklearn.

Nous avons choisis de reserver 70% des données pour l'apprentissage et les 30% restantes pour l'étape de validation.

```
[12]: X_origin=kg['claimReview_claimReviewed'] # Les assertions
y_origin=kg['ratingValue'] # les labels
```

Dans ce qui suit, nous utiliserons la classe TextPreTraitement vue précédemment (Notebook pretraitement) pour le prétraitement des données.

1.2.2 Vectorisation

L'objectif ici est de transformer l'ensemble des assertions (composées de mots) en un ensemble de vecteurs pour que les modèles puissent effectuer des opérations mathématique dessus. Il existe trois approches principales :

- Bag of Word
- TF-IDF
- Word2Vec

Nous utiliserons principalement TF-IDF pour la vectorisation des données.

```
preprocessor=lambda x:x,
    min_df=0.005,
    max_df=0.7)
```

```
[12]: vectorizer.fit(X_train)
vectorizer.fit(X_test)
vectorizer.fit(X)
```

```
vector = pd.DataFrame(
              data=vectorizer.transform(X).toarray(),
              columns=vectorizer.get_feature_names()
          )
      vector_train = pd.DataFrame(
              data=vectorizer.transform(X_train).toarray(),
              columns=vectorizer.get feature names()
          )
      vector_test = pd.DataFrame(
              data=vectorizer.transform(X_test).toarray(),
              columns=vectorizer.get_feature_names()
          )
[13]: display(vector_train.sample(5))
      display(vector test.sample(5))
               abortion accident account
                                              across
                                                           actor
                                                                  actually \
                                                     act
     4420
                                         0.0
          0.0
                     0.0
                                0.0
                                                 0.0
                                                      0.0
                                                             0.0
                                                                       0.0
           0.0
                     0.0
                               0.0
                                         0.0
                                                 0.0 0.0
                                                             0.0
                                                                       0.0
     506
     1723 0.0
                     0.0
                               0.0
                                         0.0
                                                 0.0 0.0
                                                             0.0
                                                                       0.0
     5637 0.0
                     0.0
                               0.0
                                         0.0
                                                 0.0 0.0
                                                             0.0
                                                                       0.0
     5618 0.0
                     0.0
                               0.0
                                         0.0
                                                 0.0 0.0
                                                             0.0
                                                                       0.0
           administration admit ... word work worker world
                                                                    would write \
     4420
                      0.0
                             0.0
                                       0.0
                                             0.0
                                                     0.0
                                                            0.0 0.000000
                                                                             0.0
                      0.0
                             0.0 ...
                                       0.0
                                             0.0
                                                     0.0
                                                            0.0 0.414533
                                                                             0.0
     506
     1723
                      0.0
                              0.0 ...
                                       0.0
                                             0.0
                                                     0.0
                                                            0.0 0.000000
                                                                             0.0
                              0.0 ...
                                       0.0
     5637
                      0.0
                                             0.0
                                                     0.0
                                                            0.0 0.00000
                                                                             0.0
     5618
                      0.0
                             0.0 ...
                                       0.0
                                             0.0
                                                     0.0
                                                            0.0 0.000000
                                                                             0.0
           year
                year old
                           york young
     4420
            0.0
                            0.0
                                    0.0
                      0.0
            0.0
                                    0.0
     506
                      0.0
                            0.0
            0.0
                                    0.0
                      0.0
                            0.0
     1723
     5637
                                    0.0
            0.0
                      0.0
                            0.0
     5618
            0.0
                      0.0
                            0.0
                                    0.0
     [5 rows x 416 columns]
           000
                abortion accident account across
                                                    act
                                                           actor
                                                                  actually \
     2254 0.0
                     0.0 0.000000
                                         0.0
                                                 0.0
                                                     0.0
                                                             0.0
                                                                       0.0
                                         0.0
                                                             0.0
                                                                       0.0
     701
           0.0
                     0.0 0.000000
                                                 0.0 0.0
     418
           0.0
                     0.0 0.000000
                                         0.0
                                                 0.0 0.0
                                                             0.0
                                                                       0.0
                                         0.0
                                                             0.0
                                                                       0.0
     2192 0.0
                     0.0 0.371433
                                                 0.0 0.0
                                                             0.0
     617
           0.0
                     0.0 0.000000
                                         0.0
                                                 0.0
                                                     0.0
                                                                       0.0
```

```
administration
                       admit
                                  word
                                        work
                                              worker
                                                       world would write \
2254
                  0.0
                         0.0
                                   0.0
                                          0.0
                                                  0.0
                                                          0.0
                                                                 0.0
                                                                         0.0
701
                  0.0
                                                                 0.0
                                                                         0.0
                         0.0
                                   0.0
                                         0.0
                                                  0.0
                                                          0.0
418
                  0.0
                         0.0 ...
                                   0.0
                                         0.0
                                                  0.0
                                                          0.0
                                                                 0.0
                                                                         0.0
2192
                         0.0
                                   0.0
                                         0.0
                                                                 0.0
                                                                         0.0
                  0.0
                                                  0.0
                                                          0.0
617
                  0.0
                         0.0
                                   0.0
                                         0.0
                                                  0.0
                                                          0.0
                                                                 0.0
                                                                         0.0
                                  young
          year
                year old york
2254 0.186778
                      0.0
                             0.0
                                    0.0
701
      0.000000
                      0.0
                             0.0
                                    0.0
418
      0.000000
                      0.0
                             0.0
                                    0.0
2192 0.000000
                      0.0
                             0.0
                                    0.0
617
      0.000000
                                    0.0
                      0.0
                             0.0
```

[5 rows x 416 columns]

1.2.3 Classifieur

Comme l'indique le *No free lunch theorem*, il n'existe pas de classifieur universel. Il est donc toujours nécessaire d'en évaluer plusieurs afin de trouver le plus pertinent pour notre situation.

Les algorithmes testés sont les suivants:

- SVM
- Naive Bayes
- Decision Tree
- K-nearest neighbors
- Logistic Regression

```
[13]: def gridSearch(X, y, verbose=False):
          models = dict()
          param = dict()
          models['dt'] = DecisionTreeClassifier()
          param['dt'] = {'max_depth': [15], #[5, 10, 15],
              'criterion': ['gini'],#['qini', 'entropy'],
              'min_samples_leaf': [6]} #[5,6,7]}
          models['svm'] = SVC()
          param['svm'] = {'C': [0.1],
              'gamma' : ['auto'],
              'kernel': ['linear']}
          models['nb'] = GaussianNB()
          param['nb'] = {'priors': [None]}
          models['knn'] = KNN()
          param['knn'] = {'n_neighbors': [7],
              'metric': ['euclidean']}
```

```
models['lr'] = LogisticRegression()
   param['lr'] = {'solver': ['newton-cg']}
   predictions = []
   for name, model in models.items():
        if verbose:
            print("Searching best param for "+name)
       gd_sr = GridSearchCV(estimator=model,
                         param_grid=param[name],
                         scoring='accuracy',
                         cv=2,
                         n_jobs=-1)
        gd_sr.fit(X, y)
        if verbose:
            print("Best score: "+str(gd_sr.best_score_))
       predictions.append((name,gd_sr.best_score_,gd_sr.best_estimator_,gd_sr.
→best_params_))
        del gd_sr
   return predictions
#gridSearch(vector, y)
```

```
[30]: def pretraitmentSearch(X_origin, y, verbose=False):
          options = ['base', 'stem', 'contraction', 'ponctuation']
          base_options = {'lowercase': True}
          predictions = []
          ngram=(1,2)
          vectorizer = TfidfVectorizer(
                  lowercase=False,
                  ngram_range=ngram,
                  preprocessor=lambda x:x,
                  min_df=0.005,
                  \max_{df=0.7}
          for option in options:
              if verbose:
                  print("Calcul des résultats pour "+option+ ": True")
              pretraitement = TextPreTraitement()
              for op, v in base_options.items():
                  setattr(pretraitement, '_'+op, v)
              if option != 'base':
```

```
setattr(pretraitement, '_'+option, True)
              X = pretraitement.fit_transform(X_origin)
              vectorizer.fit(X)
              vector = pd.DataFrame(
                      data=vectorizer.transform(X).toarray(),
                      columns=vectorizer.get_feature_names()
                  )
              predictions.append(gridSearch(vector, y,verbose))
              del vector, X, pretraitement
          models = \{\}
          for algo in predictions[0]:
              models[algo[0]] = pd.DataFrame([], columns=['option', 'score'])
          for option, pred in zip(options, predictions):
              for algo in pred:
                  models[algo[0]] = models[algo[0]].append({'option': option, 'score':
       → algo[1]}, ignore_index=True)
          return models
[31]: models_result = pretraitmentSearch(X_origin, y, verbose=False)
[16]: def plot_models_lines(models):
          for name, model in models.items():
              plt.plot(model['option'], model['score'], label=name,marker='.')
          plt.title('Comparaison des algorithmes')
          plt.xlabel('Prétraitements', fontsize=14)
          plt.ylabel('Accuracy (%)',fontsize=14)
          plt.grid()
          plt.legend(loc=1,bbox_to_anchor=(1.20, 1))
          plt.show()
```

[32]: plot_models_lines(models_result)

